



Что такое «большие данные»? ML на больших данных.

Лектор: Сергукова Ю.М.

2026 год

Структура лекции

01

Дорожная карта курса



02

Введение

Развитие ML. Данные – новое топливо



03

4V и больше

Технические требования к ML



04

Классический ML

Его инструментарий и ограничения



05

Обучение на BigData

Как впихнуть невпихуемое



Курс «Машинное обучение на больших данных»



Курс «Машинное обучение на больших данных»



Состав курса

14 лекций

+

13 семинаров

+

4 домашние работы



Итоговая оценка

Каждая домашняя работа приносит от 0 до 20 баллов

+

Активно отвечаете на семинарах?
Можете получить бонусные баллы (до +3 за раз)



Сколько это в баллах?

$$R = \Sigma(h_i) + b$$

>

R
В зачётку

26	36	46	56	66	76	90	105
3	4	5	6	7	8	9	10

Структура лекции

01

Дорожная карта курса



02

Введение

Развитие ML. Данные – новое топливо



03

4V и больше

Технические требования к ML



04

Классический ML

Его инструментарий и ограничения



05


Обучение на BigData

Как впихнуть невпихуемое



Золотая мечта
человечества: «Давайте
научим машину думать»

Какой путь прошёл ML?




Большие – очень большие! – языковые модели

- Моделям не нужны правила, они сами извлекают фичи из данных
- Модели учатся не конкретной задаче, а фундаментальному представлению мира и языка
- Чем больше данных, тем «умнее» модель

Данные – новое топливо



Большие – очень большие! – языковые модели



Резюме

- Разработка ИИ прошла путь от строгих закодированных правил к выделению признаков и, наконец, к работе с сырыми данными
- Чем сложнее задача, тем меньше она поддаётся ручному кодированию
- Сложные задачи требуют много данных для обучения

Структура лекции

01

Дорожная карта курса



02

Введение

Развитие ML. Данные – новое топливо



03

4V и больше

Технические требования к ML



04

Классический ML

Его инструментарий и ограничения




05

Обучение на BigData

Как впихнуть невпихуемое



Проблема 4V



Volume

- Данных нужно всё больше
- Гигабайты → терабайты → петабайты

Хранение

Не только хранить, но и сохранять целостность данных.
Распределённые системы (HDFS) или облачные решения.

Обработка

Нужно уметь собрать и получить данные от ФС.
Распределённые и параллельные вычисления (Hadoop, Spark).

Стоимость

Неоптимальное хранение (дублирование, отсутствие сжатия, избыточная репликация) = лишние затраты.

Data Governance

Безопасность данных, регулирование доступа, чувствительная информация.

Velocity

- Петабайты данных нужно не только доставить ДО вычислительных слоёв, но и получить результат ОТ них.

Своевременность

Данные должны успевать обрабатываться не медленнее, чем они поступают.

Качество

От скорости не должно падать качество обработки.
«Обработка быстро, но с ошибками» – не подходит.

Стоимость

Простой процессора = лишние затраты.

Выбери своего героя:

Batches

Real-time streaming

Variety

- Данные поступают в разных форматах:
 - Не получится хранить текст и изображения в «одной таблице»
 - Нужны адаптеры для трансформации редких форматов/извлечения информации
- Для обработки некоторых форматов нужны дополнительные навыки и знания



3V → 4V

(Volume + Velocity + Variety) – «Проблема инженера»

Как **технически** сохранить и пропустить через процессор эти огромные и разнородные данные?

Veracity – «Проблема аналитика»

А можно ли вообще доверять этим данным?

Veracity

- «Garbage in, garbage out»
- Данные – **единственный** источник знаний НС о внешнем мире

Оценка достоверности источника

Можем ли мы ему доверять?

Очистка данных

Удаление ошибок, валидация, заполнение пробелов, удаление дубликатов

Проверка данных

«Доверяй, но проверяй». Как быстро и качественно оценить достоверность большого объема данных?



Ядовитая пилюля, Bias и «галлюцинации»

Veracity – это не просто шум и опечатки

Выбор данных для обучения напрямую влияет на достоверность результата.

Data Poisoning

«Backdoor» – внедрённая систематическая ошибка, повторяющийся признак, из которой алгоритм извлекает паттерн и начинает распознавать его всегда, когда видит этот признак. Достаточно отравить 1-3% данных.

Примеры: «тригонометрический шум» как признак «кошачести», стикер на дорожном знаке как основной признак знака.

Bias

Данные не «грязные», но не репрезентативны. Алгоритм фиксирует полученную картину мира, как единственную достоверную.

Примеры: расистские и оскорбительные сообщения от чат-бота Tay (Microsoft, 2016), гендерная дискриминация в AI-рекрутинге (Amazon, 2018)

Навязанные галлюцинации

Алгоритм выдаёт странные и несоответствующие реальности ответы потому, что такие примеры были в обучающем множестве и считались достоверными.

Пример: генерация кода с использованием нереализованного функционала (GitHub Copilot, 2021)

Резюме

Недостаточно просто получить большой объём данных. Также нужно:

- Хранить их так, чтобы ими можно было пользоваться
- Уметь быстро доставлять их до вычислительных слоёв
- Уметь работать (хранить и обрабатывать) с разными типами данных
- Контролировать их качество

Структура лекции

01

Дорожная карта курса



02

Введение

Развитие ML. Данные – новое топливо



03

4V и больше

Технические требования к ML



04

Классический ML

Его инструментарий и ограничения




05

Обучение на BigData

Как впихнуть невпихуемое



Классическое ML



Инструментарий

Библиотека на Python для работы с табличными данными в памяти.

«Швейцарский нож» для Data Scientist's'a, но в первую очередь предназначен для очистки и первичной оценки.

Очень популярен, негласный стандарт.

Единица данных – DataFrame. Применяется в качестве входного формата в других модулях ML.



Инструментарий

Вычислительный движок на Python, заточенный на работу с многомерными массивами, линейную алгебру и векторизованные операции без циклов.

Скорость компилируемых языков для пользователей Python.

Можно использовать отдельно, но также находится под капотом Pandas.



Инструментарий

Библиотека классических алгоритмов на Python.

Удобный и быстрый (на Cython) функционал для получения готовой обученной модели.




Почему они не подходят для работы с большими данными?

Все эти инструменты работают в памяти.
Типичная RAM ноутбука – 16Гб.

Если попытаться запустить их на большом датасете, то Pandas упадёт с ошибкой, а Scikit даже не начнёт обучение.

Проблема «масштабирования вверх» – упёрлись в возможности одного сервера.



Проблемы не только с памятью

- Обучение сложных моделей – это миллионы и миллиарды вычислений.
- Вычислительные возможности одного ядра ограничены, а в одну машину мы можем добавить конечное (и не сильно большое) количество ядер.
- Мы всё ещё можем обучать модели на одной машине, но это будет занимать недели.



Резюме

У нас есть привычный и рабочий инструментарий, но мы не можем им воспользоваться, потому что BigData слишком велика для обработки на одной машине.

Структура лекции

01

Дорожная карта курса



02

Введение

Развитие ML. Данные – новое топливо



03

4V и больше

Технические требования к ML



04

Классический ML

Его инструментарий и ограничения



05

Обучение на BigData

Как впихнуть невпихуемое



BigData слишком велика

Как мы можем решить эту проблему?

Сэмплирование

- + Простота реализации. Продолжаем пользоваться привычными Pandas/Scikit
- Сложно составить полноценный репрезентативный сэмпл. Можем потерять редкие закономерности.


Распределённые вычисления

- + Работаем со всеми данными.
- Нужно новое ПО и инфраструктура. Придётся адаптировать алгоритмы и, возможно, данные.

BigData слишком велика

Сэмплирование используется для экспериментов и прототипирования.

Серьёзное решение – распределённые вычисления.



Новый инструментарий: Dask

«Старший брат» Pandas:

- Похожий API
- Ленивые вычисления
- Поддерживает как однопоточные, так и многопоточные вычисления
- Может использовать несколько серверов



Когда использовать?

У вас есть один сервер с многими ядрами и вы хотите максимально утилизировать ресурсы.

У вас есть небольшой кластер.



Новый инструментарий: Spark

Промышленный стандарт:

- Может работать с очень большими данными
- DataFrame API – тоже похож на Pandas
- Для конечного разработчика размеры и само наличие кластера спрятаны под капотом



Когда использовать?

У вас очень большие данные и есть много серверов, которые можно использовать для вычислений. Данные хранятся в HDFS или S3.
Бонус: экосистема Apache – сама по себе промышленный стандарт.



Резюме

Несмотря на устрашающие размеры датасетов в **петабайты** данных, обучение моделей на них возможно. Существует готовый инструментарий и уже проверенные подходы к работе.

Этому и посвящён наш курс



Спасибо за внимание!

