



Машинное обучение на больших данных


Классические алгоритмы (линейные модели и деревья решений).
Hashing trick.

AGENDA

Поговорим о данных

Как учить модели на больших данных

Что такое Hashing Trick и чем он полезен








01



Насколько большими
должны быть данные чтобы
стать «большими»?

Большие ли это данные?

Student Performance Prediction Dataset

 student_id 	# age 	 gender 	# study_hours 	# attendance 	# sleep_hours 	# previous 
A dataset containing 300,000 student records with academic, behavioral, lifestyle, and socioeconomic features	Age of the student	Gender of the student	Average daily study hours	Attendance percentage	Average daily sleep hours	Previous score
		Female 48% Male 48% Other (12046) 4%				
1	21	Male	1.6454036296818284	79.15452128189159	8.230886463424635	96.05383
2	18	Male	4.46212555447147	72.5266854617487	6.139218936153201	53.02482
3	19	Female	6.220211891936939	98.53171585056324	6.9463127356665	78.77542
4	21	Female	1.8266435144906192	97.73124466733921	8.297048370879239	76.12261
5	17	Male	3.789322360928085	78.58910699360395	6.777171235659118	81.30568
6	19	Female	3.493020280620064	87.21280775797412	6.0846851370550645	62.55579

Большое количество наблюдений

Чем больше строк в нашей таблице, тем она выше или, иначе говоря, длиннее.

Можно искусственно увеличивать длину датасета генерируя синтетические данные.



21	Male	1.6454036296818284	79.15452128189159	21
18	Male	4.46212555447147	72.5266854617487	18
19	Female	6.220211891936939	98.53171585056324	19
21	Female	1.8266435144906192	97.73124466733921	21
17	Male	3.789322360928085	78.58910699360395	17
19	Female	3.493020280620064	87.21280775797412	19
19	Male	1.8884637837633047	80.91092660109204	19
21	Female	5.25314425197192	87.16571785029478	21
16	Female	3.9210332834221906	79.49245037052255	16
17	Male	2.4754522532582186	72.70221966860532	17
21	Male	5.641941796291695	85.39583130048467	21
17	Male	5.490623908982601	95.08417439064027	17
17	Female	1.9688062537621214	78.84570702554949	17
19	Male	7.736241671387871	87.06504063152993	19
18	Male	8.029288260200152	79.20047101272091	18
17	Female	7.35912576013248	90.66122008012383	17
20	Female	5.2125603255129604	85.95606951825472	20
19	Male	6.003001739782557	82.39560059214656	19
16	Female	2.049397229850466	82.58069894618124	16
18	Female	5.934851784802299	90.32475773953632	18
20	Female	5.058148440894591	70.45016230635557	20
20	Female	1.9948266555539647	81.23520325220811	20
16	Female	0.3352839344934244	100.0	16
18	Female	6.350690446370371	88.16784132288294	18
19	Female	5.873642580702496	100.0	19
15	Male	6.767742947736971	100.0	15
18	Male	2.3463150237966097	94.84631840353558	18
16	Male	9.261043226066947	69.89086141427687	16
20	Female	5.477780940239646	81.05214795529707	20

Большое количество признаков

Чем больше столбцов в нашей таблице, тем она шире.

Feature engineering: можем пытаться извлекать больше признаков из имеющихся данных или трансформировать имеющиеся признаки.



21	Male	1.6454036296818284	79.15452128189159	21
18	Male	4.46212555447147	72.5266854617487	18
19	Female	6.220211891936939	98.53171585056324	19
21	Female	1.8266435144906192	97.73124466733921	21
17	Male	3.789322360928085	78.58910699360395	17
19	Female	3.493020280620064	87.21280775797412	19
19	Male	1.8884637837633047	80.91092660109204	19
21	Female	5.25314425197192	87.16571785029478	21
16	Female	3.9210332834221906	79.49245037052255	16
17	Male	2.4754522532582186	72.70221966860532	17
21	Male	5.641941796291695	85.39583130048467	21
17	Male	5.490623908982601	95.08417439064027	17
17	Female	1.9688062537621214	78.84570702554949	17
19	Male	7.736241671387871	87.06504063152993	19
18	Male	8.029288260200152	79.20047101272091	18
17	Female	7.35912576013248	90.66122008012383	17
20	Female	5.2125603255129604	85.95606951825472	20
19	Male	6.003001739782557	82.39560059214656	19
16	Female	2.049397229850466	82.58069894618124	16
18	Female	5.934851784802299	90.32475773953632	18
20	Female	5.058148440894591	70.45016230635557	20
20	Female	1.9948266555539647	81.23520325220811	20
16	Female	0.3352839344934244	100.0	16
18	Female	6.350690446370371	88.16784132288294	18
19	Female	5.873642580702496	100.0	19
15	Male	6.767742947736971	100.0	15
18	Male	2.3463150237966097	94.84631840353558	18
16	Male	9.261043226066947	69.89086141427687	16
20	Female	5.477780940239646	81.05214795529707	20

Большие данные

Важна «площадь»: совокупность и строк и столбцов.

21	Male	1.6454036296818284	79.15452128189159	21
18	Male	4.46212555447147	72.5266854617487	18
19	Female	6.220211891936939	98.53171585056324	19
21	Female	1.8266435144906192	97.73124466733921	21
17	Male	3.789322360928085	78.58910699360395	17
19	Female	3.493020280620064	87.21280775797412	19
19	Male	1.8884637837633047	80.91092660109204	19
21	Female	5.25314425197192	87.16571785029478	21
16	Female	3.9210332834221906	79.49245037052255	16
17	Male	2.4754522532582186	72.70221966860532	17
21	Male	5.641941796291695	85.39583130048467	21
17	Male	5.490623908982601	95.08417439064027	17
17	Female	1.9688062537621214	78.84570702554949	17
19	Male	7.736241671387871	87.06504063152993	19
18	Male	8.029288260200152	79.20047101272091	18
17	Female	7.35912576013248	90.66122008012383	17
20	Female	5.2125603255129604	85.95606951825472	20
19	Male	6.003001739782557	82.39560059214656	19
16	Female	2.049397229850466	82.58069894618124	16
18	Female	5.934851784802299	90.32475773953632	18
20	Female	5.058148440894591	70.45016230635557	20
20	Female	1.9948266555539647	81.23520325220811	20
16	Female	0.3352839344934244	100.0	16
18	Female	6.350690446370371	88.16784132288294	18
19	Female	5.873642580702496	100.0	19
15	Male	6.767742947736971	100.0	15
18	Male	2.3463150237966097	94.84631840353558	18
16	Male	9.261043226066947	69.89086141427687	16
20	Female	5.477780940239646	81.05214795529707	20

02




Учим модели на данных с
большим количеством
наблюдений

Линейная регрессия

$$y = w_0 + w_1x_1 + w_2x_2 + \dots + \varepsilon$$

$$w = (X^T X)^{-1} X^T Y$$



Линейная регрессия на длинных таблицах

Строк настолько много, что они физически не влезают разом в память.

✓
Mini-batch SGD: Теперь размер нашего батча позволяет модели учиться. Но это всё равно может быть долго.

✓
Multi-node: Хорошо ложится на map-reduce и доставку кода к данным: мы будем доставлять не батч к модели, а модель к батчу


21	Male	1.6454036296818284	79.15452128189159	21
18	Male	4.46212555447147	72.5266854617487	18
19	Female	6.220211891936939	98.53171585056324	19
21	Female	1.8266435144906192	97.73124466733921	21
17	Male	3.789322360928085	78.58910699360395	17
19	Female	3.493020280620064	87.21280775797412	19
19	Male	1.8884637837633047	80.91092660109204	19
21	Female	5.25314425197192	87.16571785029478	21
16	Female	3.9210332834221906	79.49245037052255	16
17	Male	2.4754522532582186	72.70221966860532	17
21	Male	5.641941796291695	85.39583130048467	21
17	Male	5.490623908982601	95.08417439064027	17
17	Female	1.9688062537621214	78.84570702554949	17
19	Male	7.736241671387871	87.06504063152993	19
18	Male	8.029288260200152	79.20047101272091	18
17	Female	7.35912576013248	90.66122008012383	17
20	Female	5.2125603255129604	85.95606951825472	20
19	Male	6.003001739782557	82.39560059214656	19
16	Female	2.049397229850466	82.58069894618124	16
18	Female	5.934851784802299	90.32475773953632	18
20	Female	5.058148440894591	70.45016230635557	20
20	Female	1.9948266555539647	81.23520325220811	20
16	Female	0.3352839344934244	100.0	16
18	Female	6.350690446370371	88.16784132288294	18
19	Female	5.873642580702496	100.0	19
15	Male	6.767742947736971	100.0	15
18	Male	2.3463150237966097	94.84631840353558	18
16	Male	9.261043226066947	69.89086141427687	16
20	Female	5.477780940239646	81.05214795529707	20

Дерево решений на длинных таблицах

Жадный алгоритм. Из этого уже следует, что совершенно точно нельзя судить о том, что итоговое дерево будет самым оптимальным из возможных.

Изначально придуман только для категориальных признаков. Но в том числе и плюс, что может нативно работать с ними.

Активно применяются эвристики и оптимизации: уменьшение признаков для перебора, предварительная сортировка значений,




Распределенное обучение дерева

Предварительная подготовка для непрерывных признаков:

1. Определение порогов для гистограмм
2. Дискретизация значений

Шаги для всех признаков:

1. Заполнение бинов значениями
2. Мержевание гистограмм для каждого признака
3. Выбор оптимального порога для каждого признака и каждого разбиения
4. Повторяем до критерия останова




03



Учим модели на данных с
большим количеством
признаков. Hashing trick

Идея

$$\begin{array}{ccccccccc} + & - & - & & + & - & & & \\ [1 & 0 & 1 & 1 & 0 & 0 & 1 & 0 & 1] \end{array}$$

$$[1 \ 0 \ -2]$$


$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$$

Выбираем независимо:

$$h \in [n] \rightarrow [m]$$

$$\sigma_1, \dots, \sigma_n \in \{-1, 1\}$$

$$f(x) \in \mathbb{R}^m := \forall x \in \mathbb{R}^n$$

$$(f(x))_i = \sum_{j: h(j)=i} \sigma_j x_j$$

Обоснование

Пусть даны

$$\varepsilon, \delta \in (0, 1)$$

Хотим найти случайную

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$$

Такую, чтобы

$$\forall x, y \in \mathbb{R}^n$$

$$\mathcal{P}(\|f(x) - f(y)\|_2^2 \in (1 \pm \varepsilon)\|x - y\|_2^2) \geq 1 - \delta$$

$$\mathcal{P}(\|f(x - y)\|_2^2 \in (1 \pm \varepsilon)\|x - y\|_2^2) \geq 1 - \delta$$

$$\mathcal{P}(\|f(x)\|_2^2 \in (1 \pm \varepsilon)\|x\|_2^2) \geq 1 - \delta$$

$$m = \mathcal{O}\left(\frac{\lg \frac{1}{\delta}}{\varepsilon^2}\right)$$

Обоснование

$$\mathcal{P}(h(1) = h(2)) = \frac{1}{m} \qquad m \geq \frac{1}{\delta}$$

$$||x||_2 := \sqrt{\sum_{i=1}^n x_i^2}$$

$$||x||_\infty := \max_i |x_i|$$

$$\nu(m, \varepsilon, \delta) := \max \{ \nu \in \mathbb{R} : \forall x \in \mathbb{R}^n, ||x||_\infty \leq \nu ||x||_2 \}$$



Спасибо за внимание!

