




Трекинг экспериментов. K8S & ML.


Лекция 13.

2026, Дубинин Владимир

Работа ML-специалиста



Работа ML-специалиста



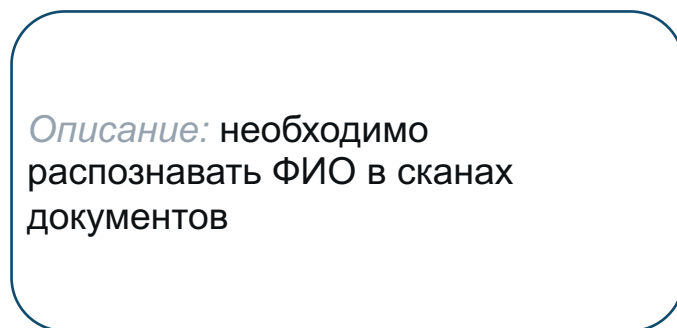
Постановка задачи

Продуктовая задача


Описание: необходимо
распознавать ФИО в сканах
документов

Постановка задачи

Продуктовая задача



Сборка датасета




Постановка задачи

Продуктовая задача

Описание: необходимо
распознавать ФИО в сканах
документов

Сборка датасета




 Задания

Постановка задачи

Продуктовая задача

Описание: необходимо
распознавать ФИО в сканах
документов

Сборка датасета



 Задания



Хочу понять как
был собран
датасет.
Что делать?

Lineage датасетов

Lineage датасета – это законченный рецепт получения конечно датасета из сырых источников, включая все промежуточные этапы трансформации и обработки данных.



Lineage датасетов

Lineage датасета – это законченный рецепт получения конечно датасета из сырых источников, включая все промежуточные этапы трансформации и обработки данных.




Данную задачу решают
специальные инструменты –
Data Catalog

Data Catalog

Примеры популярных Data Catalog:

- Marquez
- OpenMetadata
- DataHub
- и т.д.




Data Catalog

Примеры популярных Data Catalog:


- Marquez
- OpenMetadata
- DataHub
- и т.д.




Теперь знаем из
каких данных и как
был составлен
датасет



Постановка задачи



Работа ML-специалиста



Предобработка данных

Для обучения ML модели необходимо подготовить данные. Для консистентности исходных данных используют **Feature Store**.

Предобработка данных

Для обучения ML модели необходимо подготовить данные. Для консистентности исходных данных используют **Feature Store**.

Feature Store – это управляемое специализированное хранилище, предназначенное для безопасного хранения, обновления, публикации и совместного использования ML-признаков.



Feature Store. Особенности

01

Консистентность данных

- Следит за консистентностью данных для воспроизводимости ML экспериментов
- Позволяет наблюдать за версиями и логикой расчета фичей на исторической прямой

02

Гарант качества


- Интегрируется с различными источниками данных и является точкой входа по работе с ними
- Поддерживает работу с моделями в потоковом режиме

03



Lineage данных

- Позволяет получить подробный рецепт формирования фичей от сырых данных (датасета)
- Позволяет получить связи между ML моделями и данными, на которых они обучались


Работа ML-специалиста



Обучение моделей





Среда обучения




Обучение

Среда обучения

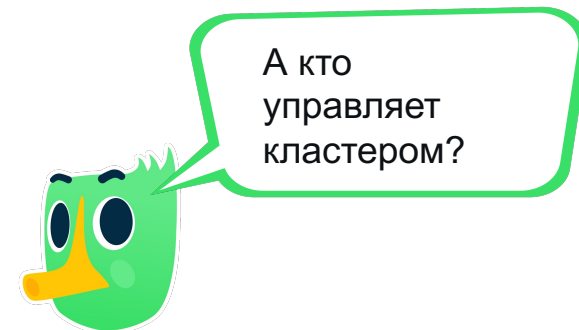

Для обучения
необходимы
ресурсы



Кластер ресурсов в IT



Кластер ресурсов в IT



Kubernetes

Kubernetes – это программная платформа для автоматического управления контейнеризованными приложениями.

Kubernetes

Kubernetes – это программная платформа для автоматического управления контейнеризованными приложениями.

Нода – физическая или виртуальная машина, на которых развертываются и запускаются контейнеры с приложениями

1. **Master-нода** – нода, управляющий всем кластером.
2. **Worker-нода** – нода, на которых работают контейнеры.



Kubernetes

Kubernetes – это программная платформа для автоматического управления контейнеризованными приложениями.

Нода – физическая или виртуальная машина, на которых разворачиваются и запускаются контейнеры с приложениями

1. **Master-нода** – нода, управляющий всем кластером.
2. **Worker-нода** – нода, на которых работают контейнеры.


Совокупность нод образует
кластер Kubernetes



Kubernetes. Поды

Pod (Под) – абстрактный объект Kubernetes, представляющий собой «обертку» для одного или группы контейнеров.

Нода № 1




Kubernetes. Поды

Pod (Под) – абстрактный объект Kubernetes, представляющий собой «обертку» для одного или группы контейнеров.


Kubernetes выделяет ресурсы (CPU, GPU, RAM) на под.

Под и все его контейнеры функционируют на одном узле и находятся там до завершения работы.


Нода № 1



Обучение моделей




Обучение моделей



Запуск задач обучения

За запуск задач обучения ответственен **scheduler**


Scheduler – компонент, который отвечает за запуск задач обучения и эффективному выделению ресурсов



Scheduler

Scheduler решает следующие проблемы:


1. Приоритезация задач обучения



Scheduler

Scheduler решает следующие проблемы:


1. Приоритезация задач обучения
2. Вытеснение задач обучения



Scheduler

Scheduler решает следующие проблемы:


1. Приоритезация задач обучения
2. Вытеснение задач обучения



Scheduler

Scheduler решает следующие проблемы:

1. Приоритезация задач обучения
2. Вытеснение задач обучения
3. Коллокация задач обучения




Scheduler


Scheduler решает следующие проблемы:

1. Приоритезация задач обучения
2. Вытеснение задач обучения
3. Коллокация задач обучения


Данную проблему решают с помощью affinity правил + использование жадного алгоритма




Обучение моделей




Квотирование ресурсов




Квотирование ресурсов




Квотирование ресурсов




Квотирование ресурсов




Обучение моделей



Обучение моделей



Работа ML-специалиста



Трекинг

Трекинг экспериментов – это процесс, включающий:

- **Сохранение.** Хранение артефактов для воспроизводимости эксперимента.
- **Организацию.** Структурирование экспериментов с настраиваемым доступом.
- **Анализ.** Сравнение результатов и исследование изменений.

Трекинг


Трекинг экспериментов – это процесс, включающий:

- **Сохранение.** Хранение артефактов для воспроизводимости эксперимента.
- **Организацию.** Структурирование экспериментов с настраиваемым доступом.
- **Анализ.** Сравнение результатов и исследование изменений.

Проблемы, которые решает трекинг:

- Сравнение моделей друг с другом
Необходимо понять какая модель лучше подойдет для решения задачи
- Сравнение версий одной модели (дотюнил датасет или параметры, хочу понять как изменилось качество)
Обновил датасет, хочу понять как изменилось качество
- Проверка гипотез
Новые алгоритмы, аугментация данных и т.п.

Артефакты эксперимента




Инструменты для трекинга


Open-Source




Commercial




Weights & Biases





Работа ML-специалиста




Инференс модели

Инференс модели – это процесс использования обученной модели для получения предсказаний на основе новых, ранее не известных данных.

Инференс модели

Инференс модели – это процесс использования обученной модели для получения предсказаний на основе новых, ранее не известных данных.


Для инференса модель оборачивают в API сервис (**MaaS – Model as a service**) с помощью фреймворков



Инференс модели

Инференс модели – это процесс использования обученной модели для получения предсказаний на основе новых, ранее не известных данных.

Для инференса модель оборачивают в API сервис (**MaaS – Model as a service**) с помощью фреймворков



Популярные инференс фреймворки:

- Triton Inference Server
- vLLM (для LLM)
- SGLang



NVIDIA


TRITON INFERENCE SERVER



Инференс модели


Инференс модели – это процесс использования обученной модели для получения предсказаний на основе новых, ранее не известных данных.

Для инференса модель оборачивают в API сервис (**MaaS – Model as a service**) с помощью фреймворков



При инференсе, также необходимо уметь разделять ресурсы, т.е. внедрить **квотирование**

Работа ML-специалиста




Автоматизация дообучения

Автоматизация дообучения необходима для поддержания модели в актуальном состоянии. Данный процесс можно построить с помощью **ML пайплайнов**.

Популярные инструменты для построения ML пайплайнов:

- Airflow
- DVC
- KubeFlow



Пример типичного ML пайплайна

Airflow

Apache Airflow — это платформа с открытым исходным кодом для оркестровки, планирования и мониторинга сложных конвейеров обработки данных.

Пропагандирует **control flow**.




Пример Airflow DAG

DVC

DVC – это система контроля версий с открытым исходным кодом, предназначенная для управления данными, ML-моделями и пайплайнами в ML проектах.


Пропагандирует **data flow**.




Пример DVC DAG

Control Flow vs Data Flow

Control Flow явно задает порядок выполнения задач, т.е. “задача В” выполняет после завершения того как завершится “задача А”



Data Flow использует изменение данных для порядка выполнения задач, т.е. запусти обучение после изменения датасета



Воспроизводимые пайплайны

Готовые инструменты имеют серьезный недостаток – **воспроизводимость пайплайнов**

Воспроизводимые пайплайны

Готовые инструменты имеют серьезный недостаток – **воспроизводимость пайплайнов**.


Воспроизводимые пайплайны – это пайплайны, которые можно использовать для решения похожих задач, т.е. уже предоставляет готовое решение для некоторой ML задачи в точности до контекста.

Воспроизводимые пайплайны


Готовые инструменты имеют серьезный недостаток – **воспроизводимость пайплайнов**.

Воспроизводимые пайплайны – это пайплайны, которые можно использовать для решения похожих задач, т.е. уже предоставляет готовое решение для некоторой ML задачи в точности до контекста.

Воспроизводимые пайплайны **позволяют** проводить экспериментирование при создании моделей.



Работа ML-специалиста




Мониторинг моделей. Prometheus

Для мониторинга моделей используют специальные инструменты. Стандартом для сбора метрик является **Prometheus**.

Prometheus – это популярная система мониторинга и оповещения с открытым исходным кодом, предназначенная для сбора, хранения и анализа метрик в режиме реального времени

What does Prometheus do?



Мониторинг моделей. Grafana

Grafana – инструмент визуализации и анализа информации, которая позволяет «из коробки» работать с широким спектром источников данных.

Работает в том числе с Prometheus.




Health Assurance


Оффлайн-оценки не гарантируют корректное поведение модели в проде
долгосрочной перспективе

Health Assurance

- Мониторинг дрифта фичей
- Мониторинг изменения потока запросов




Health Assurance. Пример



Реализация Health Assurance в LinkedIn

ИТОГИ



Резюме лекции

- Познакомились с k8s
- Изучили процесс обучения ML моделей в big tech компаниях
- Узнали что такое трекинг
- Ознакомились с процессом регулярного обучения
- Выяснили зачем нужен Health Assurance

Вопросы?

